

Στατιστική

Statistics -- Περιγραφικά Μέτρα & Αναπαράσταση Δεδομένων

SAT Math -- Σημειώσεις

1 Βασικές Έννοιες

Data set -- σύνολο δεδομένων

$$A = \{1, 2, 3, 4, \dots, 7\}$$

Frequency (συχνότητα): πόσες φορές εμφανίζεται μια τιμή μέσα σε ένα data set.
Mode (επικρατούσα τιμή): η τιμή με τη **μέγιστη** συχνότητα.

Παράδειγμα

$$B = \{1, 1, 1, 2, 2, 2, 5, 6, 7, 8, 10, 10, 10, 10\}$$

$$\text{freq}(1) = 3 \quad \text{freq}(2) = 3 \quad \text{freq}(10) = 4$$

Αφού το 10 έχει τη μεγαλύτερη συχνότητα: $\text{mode}(B) = 10$

1.1 Τρόποι αναπαράστασης τιμών


(A) Dot plot

κάθε παρατήρηση → μία τελεία
πάνω από την τιμή της

(B) Histogram


ραβδόγραμμα συχνοτήτων ανά
διάστημα τιμών

Παράδειγμα Dot plot (σύνολο C):



$\text{mode}(C) = 3$ (η στήλη με τις περισσότερες τελείες)

2 Ιστόγραμμα (Histogram)



Το ιστόγραμμα **χρησιμοποιείται** όταν δεν μας ενδιαφέρει (ή δεν γνωρίζουμε) η **ακριβής τιμή** κάθε παρατήρησης, αλλά μόνο το **διάστημα** (εύρος τιμών) μέσα στο οποίο βρίσκεται.

Παράδειγμα: στο data set D υπάρχουν 4 παρατηρήσεις με τιμές **ανάμεσα** στο 1 και στο 3 -- χωρίς να μας ενδιαφέρει ποιες ακριβώς είναι αυτές οι τιμές, παρά μόνο το ότι ανήκουν σε αυτό το διάστημα.

3 Μέτρα Θέσης ενός Data Set


Mean (μέσος όρος)

$$\text{mean} = \frac{\text{sum}}{\text{total}}$$

SD -- Standard Deviation (τυπική απόκλιση)

η **αναμενόμενη απόσταση** μιας τυχαίας παρατήρησης του data set από τον μέσο όρο

Σύγκριση διασποράς -- $n = 10$



(Με το μάτι): το data set B είναι πιο «μαζεμένο» γύρω από τον μέσο όρο, άρα

$$SD_A > SD_B$$

όπου SD_A = τυπική απόκλιση των στοιχείων του A , SD_B = τυπική απόκλιση του συνόλου B .

4 Εύρος (Range) & Διάμεσος (Median)

Range

Range = max – min
(εύρος του συνόλου)

Median

η **ενδιάμεση** παρατήρηση στη
διατεταγμένη σειρά
δεδομένων
(αύξουσα ή φθίνουσα)

Λυμένο παράδειγμα -- εύρεση διαμέσου

$$A = \{1, 10, -1, -8, 7, 15, 3, 21, -7, 10\}$$

Τα βάζουμε σε αύξουσα διάταξη:

$$-8 < -7 < -1 < 1 < \underline{3} < \underline{7} < 10 < 10 < 15 < 21$$

Το σύνολο έχει $n = 10$ (ζυγός αριθμός) στοιχεία, άρα η διάμεσος είναι ο **μέσος όρος** των δύο μεσαίων τιμών (5ης και 6ης θέσης):

$$\text{median} = \frac{3 + 7}{2} = 5$$

Κανόνες: αν το πλήθος n των παρατηρήσεων είναι

- **περιττό** -- η διάμεσος είναι η ακριβώς μεσαία τιμή
- **άρτιο** -- η διάμεσος είναι ο μέσος όρος των δύο μεσαίων τιμών

Σύνοψη

Μέγεθος	Τι εκφράζει
Frequency	πόσες φορές εμφανίζεται μια τιμή στο data set
Mode	η τιμή με τη μέγιστη συχνότητα
Mean	μέσος όρος = $\frac{\text{sum}}{\text{total}}$
SD	αναμενόμενη απόσταση μιας παρατήρησης από τον μέσο όρο (διασπορά)
Range	$\text{max} - \text{min}$
Median	μεσαία τιμή στη διατεταγμένη σειρά (ή μέσος όρος των δύο μεσαίων, αν n άρτιο)

Για εξάσκηση

Δοκίμασε μόνος/η σου

1. Για το σύνολο $E = \{4, 4, 4, 6, 6, 9, 9, 9, 9, 12\}$, βρες: (α) τη συχνότητα κάθε τιμής, (β) το mode.
2. Δύο σύνολα X και Y έχουν τον **ίδιο** μέσο όρο, αλλά το X έχει μεγαλύτερη τυπική απόκλιση από το Y . Τι σημαίνει αυτό για τη διασπορά των τιμών τους;
3. Για το σύνολο $F = \{-5, 12, 3, 0, 7, -2, 9\}$, βρες το range και τη διάμεσο.